

# Algoritmos de agregação de utilizadores em aplicações de segurança rodoviária ITS-C

José Barbosa      Leonardo Fontes      Tiago Moreira

Maio de 2023

## Resumo

Este artigo discute a aplicação e adaptação de tecnologias de clustering no contexto das redes viárias e as suas aplicações em segurança rodoviária. Falamos de tecnologias de deteção tradicionais e de agrupamentos. São abordadas a viabilidade, vantagens, limitações e exemplos hipotéticos do uso dessas tecnologias, além da proposta de uma abordagem combinada técnicas tradicionais para promover a segurança de (V.R.Us) Vulnerable Road Users.

## 1 Introdução

A segurança rodoviária tem tido uma evolução em grande escala nos últimos anos, com grandes passos dados neste ramo, ao ponto em que o mundo em que nós vivemos atualmente possui carros capazes de estacionar sozinhos e outros, mais evoluídos, que são capazes de conduzir com mínimo input do condutor. Contudo, apesar desta era de crescimento em que vivemos, continua a existir um problema que as grandes empresas e desenvolvedores ainda não conseguiram decifrar. Este corresponde aos URV (Utilizadores Rodoviários Vulneráveis (pedestres, ciclistas, etc)), uma vez que são frequentemente vítimas de acidentes de trânsito, muitos dos quais resultam na sua morte. Este é o caso, uma vez que, atualmente, é praticamente impossível detetar individualmente cada um dos URV, na maior parte dos ambientes urbanos. A agregação e processamento de veículos em grupos, ou "clusters", é um processo bem conhecido em sistemas de gestão de tráfego veicular. O passo seguinte desta técnica será, naturalmente, pensar como se a adaptar para agrupamentos de todos os tipos de utilizadores rodoviários, incluindo também os URV. Através deste mecanismo de agregação, ponderamos na possibilidade duma implantação futura em aplicações de segurança em sistemas cooperativos e inteligentes de transporte rodoviário, os ITS-C ("Cooperative Intelligent Transport Systems") , com o objetivo de passar a segurança rodoviária para o próximo nível, aumentando a eficiência e a escalabilidade, quando comparada ao que temos nos dias de hoje. Esta é uma área em crescimento na indústria de transporte, que abrange uma variedade de

sistemas inteligentes capazes de melhorar a eficiência e a segurança do trânsito rodoviário. Os mesmos incluem sistemas de navegação, de gestão de trânsito e de monitoramento de veículos. Os sistemas ITS-C podem ainda ser usados para melhorar a mobilidade e a acessibilidade de pessoas com deficiência e idosos, através de tecnologias como veículos adaptados, sistemas de navegação por voz, e interfaces de usuário acessíveis. Além da agregação de veículos em grupos, existem outras tecnologias que podem ser usadas para melhorar a segurança rodoviária, como sensores de detecção de pedestres e ciclistas, ou até mesmo veículos autônomos que possam comunicar uns com os outros e com o ambiente que os rodeia. Este artigo tem como objetivo explorar a possibilidade da utilização de clusters e explorar como podemos evoluir esta tecnologia como maneira de melhorar a segurança rodoviária, com especial foco nos URV. Esperamos com este artigo trazer uma perspectiva nova a este tópico. O artigo estará dividido da seguinte forma. Na seção 2 falaremos de tecnologias de detecção tradicionais, basicamente o state-of-the-art das tecnologias de detecção. Na seção 3 falaremos das tecnologias de detecção por agrupamentos, ou seja, outras técnicas que também são utilizadas, neste caso para detecção e previsão de movimentos de seres vivos, não necessariamente num contexto urbano. Na seção 4, vamos discutir com base no que estudamos o que nós achamos ser melhor e mais viável para atingir o nosso objetivo. E na seção 5 as conclusões finais.

## 2 Tecnologias de detecção tradicionais

### 2.1 Sensorização

A sensorização de pedestres pode ser feita de diversas formas [1], incluindo câmara estéreo [22], LIDAR (Light Detection and Ranging) [23], radar (Radio Detection and Ranging) [24], sensor infravermelho [25], identificação por radiofrequência [26] e sensor ultrassônico [27].

A tabela 1 dá nos alguma informação sobre a precisão e a distância que cada tipo de sensor é capaz de cobrir.

As câmaras estéreo utilizam duas ou mais câmaras para criar uma perspectiva 3D do cenário. Elas capturam imagens e utilizam de algoritmos de visão estéreo para calcular a profundidade da informação. Elas são capazes de obter com precisão a posição de pedestres e devido a disparidade da posição das lentes, não enfrentam problemas com as variações da luz. Podem, no entanto, enfrentar problemas de oclusão, especialmente quando pedestres ou objetos obstruem uns aos outros. Além disso, a sua eficácia diminui em longas distâncias. São popularmente utilizadas pelo custo-benefício, porque apesar de ter estas limitações, elas apresentam uma solução viável para performance em tempo real e é relativamente barata comparada com outras tecnologias deste contexto [1] [22].

LIDAR é uma tecnologia de sensorização remota que utiliza raios laser para medir distância até objetos e criar uma representação 3D do ambiente. Permite uma detecção e localização precisa dos pedestres. Estes sensores são capazes de

Tabela 1: Distância coberta e precisão dos sensores mais comuns para detecção de pedestres. (Tabela adaptada de [1])

Sensores	Distância Coberta	Precisão
Câmaras estéreo	500 cm a muitas dezenas de metros	Divergência de 1/10 pixeis (corresponde a um erro de 1 metro se o alvo está a 100m de distancia.
Infravermelhos	Vários centímetros	Precisão de temperatura de +/- 10 graus Celsius
Sensor Ultrasónico	20mm a 5000mm	Aproximadamente 0.03 cm
Radiofrequência	Alguns metros	Alguns centímetros
LIDAR	De 300 metros para cima	De 2 centímetros para cima
RADAR	Tamanho e ângulos variáveis	Depende do tamanho e da área coberta

realizar detecção de longo alcance e fornecem dados de alta resolução, isto é, com detalhes. Além disto, as condições de luz não os afetam e podem operar em ambientes variados. O LIDAR pode não funcionar bem em neblina, neve e chuva, podendo não fornecer dados que as câmaras normalmente conseguem capturar, como texto em placas ou a cor dos semáforos. É uma tecnologia cara, mas que tem uma ampla utilização na detecção de pedestres em veículos autônomos por exemplo, devido a sua precisão, alcance e fiabilidade [1] [23].

Radar é uma tecnologia de sensorização que utiliza ondas de rádio para detectar e localizar objetos no ambiente. Sensores de radar emitem sinais de rádio e medem o tempo que leva para os sinais retornarem após atingir objetos, incluindo pedestres. O radar oferece detecção confiável de pedestres e pode operar efetivamente em diversas condições climáticas. Ele oferece capacidades de longo alcance e pode funcionar tanto durante o dia quanto à noite. No entanto, o radar pode ter uma resolução espacial limitada em comparação com outros métodos de sensorização, o que pode afetar a capacidade de distinguir com precisão pedestres de outros objetos [1] [24].

Os sensores infravermelhos têm a capacidade de detectar o calor emitido por objetos, incluindo pedestres, e criar imagens térmicas que mostram as diferentes temperaturas presentes no cenário. Eles são eficazes em condições de pouca luz e podem detectar pedestres mesmo em completa escuridão. Além disto, são menos afetados por obstruções visuais e podem fornecer detecção confiável em diversas condições climáticas. Os sensores infravermelhos podem ter dificuldade em capturar detalhes finos em comparação com outros métodos de sensorização. Outra limitação é que dependem principalmente das assinaturas de calor, então a sua precisão pode ser influenciada por fatores como variações da temperatura ambiente [1] [25].

A Identificação por Radiofrequência é uma tecnologia que usa campos eletromagnéticos para identificar e rastrear objetos ou pessoas. No caso da detecção

de pedestres, pode ser utilizado para saber se há pessoas por perto através de etiquetas ou dispositivos que elas carregam. Funciona com leitores que emitem ondas de rádio e etiquetas de identificação por radiofrequência (dispositivos eletrônicos pequenos que contêm um chip e uma antena) que respondem com informações de identificação. Este sensor não requer contacto direto e pode ser usado em diferentes ambientes. Porém, ele tem limitações na precisão para localizar exatamente os pedestres [1] [26] .

Os sensores ultrassônicos emitem ondas sonoras de alta frequência e medem o tempo que leva para as ondas retornarem após atingir objetos, incluindo pedestres. Esses sensores podem fornecer detecção de proximidade e medidas de distância com base nas ondas sonoras refletidas. Os sensores ultrassônicos têm um custo relativamente baixo, são leves e podem operar em várias condições de iluminação, incluindo a escuridão. Eles oferecem medições de distância confiáveis em curtas a médias distâncias. No entanto, os sensores ultrassônicos têm limitações em termos de resolução e precisão em comparação com outros métodos de sensorização. Eles podem ter dificuldade em distinguir com precisão pedestres de outros objetos ou obstáculos em ambientes complexos, devido à resolução espacial limitada e dificuldades em diferenciar formas humanas [1] [27].

## 2.2 Processamento de dados

Ao longo dos anos muitas tecnologias foram desenvolvidas com base em machine-learning para detecção de objetos individualmente, como SVM (Support Vector Machine), HOG (Histogram of Oriented Gradients), Haar. Dentro da categoria de machine-learning há aquelas que utilizam aprendizagem profunda (deep-learning). Esta última têm ganho mais relevância devido a uma grande melhoria na precisão e eficiência relativamente às técnicas anteriores, principalmente as que utilizam redes neurais convulsionais, constituindo o estado da arte atual.

Podemos dividir estas técnicas em 2 categorias: detetores de uma etapa e detetores de duas etapas. A primeira destas, que inclui tecnologias como YOLO (You Only Look Once) e SSD (Single Shot Detector), que são capazes de detectar objetos apenas passando pela imagem uma vez, sem precisar de uma etapa separada para propôr regiões onde possam estar objetos. Já a segunda, inclui tecnologias como R-CNN (Region-based Convolutional Neural Network) , Fast R- CNN e Faster R-CNN. Estas têm uma segunda etapa onde vão voltar a passar pela imagem para propôr regiões onde os objetos possam estar, seguidos da classificação dos objetos [1].

YOLO é uma técnica de detecção de objetos baseada em CNN que divide a imagem numa grade de células e, em cada célula, prevê a presença de objetos e sua classe, bem como a caixa delimitadora que envolve o objeto. Além disso, o YOLO é capaz de detetar objetos em escalas diferentes e possui uma arquitetura simples e eficiente. Esta técnica é amplamente utilizada em sistemas de visão computacional para tarefas de detecção de objetos em tempo real [1] [17]. SSD

Tabela 2: R-CNN comparação de velocidade (Tabela adaptada de [16])

	R-CNN	FAST R-CNN	FASTER R-CNN
Tempo de teste por imagem	50seg	2seg	0.2seg
(Speedup)	1x	25x	250x
mAP (mean Average Precision)	66.0	66.9	66.9

Tabela 3: FPS dos modelos de deep learning onde o GPU é GeForce RTX 2080Ti(Tabela adaptada de [16])

	YOLO	SSD	FASTER R-CNN
FPS	82.1	105.14	36.32

Tabela 4: Avaliação dos Deep learning models (F1score combina a precisão e a recuperação de um classificador em uma única métrica, tomando sua média harmônica)(Tabela adaptada de [16])

Models	F1score	Precision	Recall	mAP
YOLO	0.96	0.93	0.98	98.19
SSD	0.88	0.90	0.87	90.56
YOLO	0.90	0.86	0.94	93.40

é uma técnica de detecção de objetos baseada em redes neurais convulsionais, sendo que utiliza este tipo de rede para extrair características de uma imagem e, de seguida, usa camadas de detecção em várias escalas diferentes de modo a prever as caixas delimitadoras de objetos. As detecções em várias escalas são fundidas com o objetivo de produzir detecções finais. Ele é usado numa grande variedade de aplicações, incluindo aplicações de videovigilância, reconhecimento de tráfego e robótica [1] [18]. O SSD é mais lento que o YOLO, mas ainda assim é rápido o suficiente para ser utilizado em aplicações de tempo real.

R-CNN (Region-based Convolutional Neural Network). Esta começa por dividir uma imagem em várias regiões menores. De seguida, extrai características com recurso a uma rede neural convolucional (CNN) e classifica cada região caso tenha ou não um objeto. No fim deste processo, faz um refinamento da localização e do tamanho do objeto dentro da região selecionada. É considerado um dos primeiros algoritmos de detecção de objetos baseado em CNN a serem propostos e tem várias variações que melhoram a velocidade e a precisão da detecção de objetos. O R-CNN é conhecido pela sua alta precisão e é principalmente utili-

Figura 1: Exemplificação por imagens do modelo YOLO. (Imagem adaptada de [17])

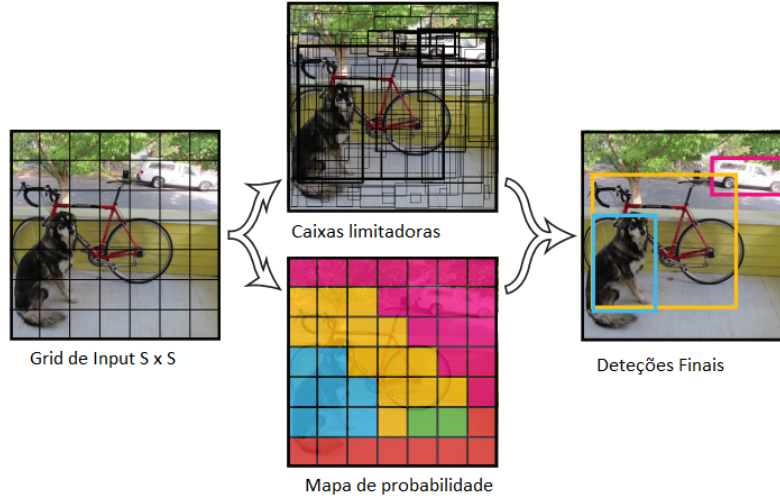



Figura 2: Exemplificação do modelo SSD: (Imagem adaptada de [18])



zado para detecção de objetos em imagens estáticas. Assim, é aplicado em áreas como análise de imagens médicas, videovigilância ou até mesmo na detecção de objetos em satélites, contudo, o seu processamento é muito lento, o que a torna uma má técnica aplicações de tempo real [1] [19].

O Fast R-CNN é uma evolução do R-CNN, apresentando mais rapidez e precisão. Ele utiliza uma única rede neural convolucional para extrair características de uma imagem inteira, em vez de extrair características separadamente para cada região da imagem. Este método também introduz uma camada de RoI (Region of Interest) que permite que a rede neural identifique regiões de interesse na imagem. Assim como o R-CNN, ele também é utilizado maioritariamente para detecção de imagens estáticas. No entanto, como a sua velocidade é maior, ainda permite ser aplicado em algumas aplicações em tempo real, como em sistemas de detecção de objetos em câmaras de vigilância. Apesar desta melhoria, esta técnica continua a ser considerada relativamente lenta para algumas aplicações

em tempo real, por exemplo de segurança rodoviária [1] [20].

Figura 3: Exemplificação do modelo R-CNN. (Imagem adaptada de [19])





Figura 4: Exemplificação do modelo Fast R-CNN: (Imagem retirada de [18])



O Faster R-CNN também é uma evolução do R-CNN. Em vez de usar o algoritmo de busca seletiva no mapa de características para identificar as propostas de região (como é feito pelo R-CNN e Fast R-CNN), o Faster R-CNN usa uma rede separada com o objetivo de prever as propostas de região, Region Proposal Network (RPN). As propostas de região previstas são então remodeladas usando uma camada de pooling de Região de Interesse (RoI), que é usada para classificar a imagem dentro da região proposta e prever os valores de deslocamento das caixas delimitadoras. Devido à eliminação desta busca seletiva, o algoritmo é muito mais rápido que os dois citados anteriormente. Este método tem sido utilizado em várias áreas, incluindo videovigilância e detecção de veículos autônomos [1] [21].

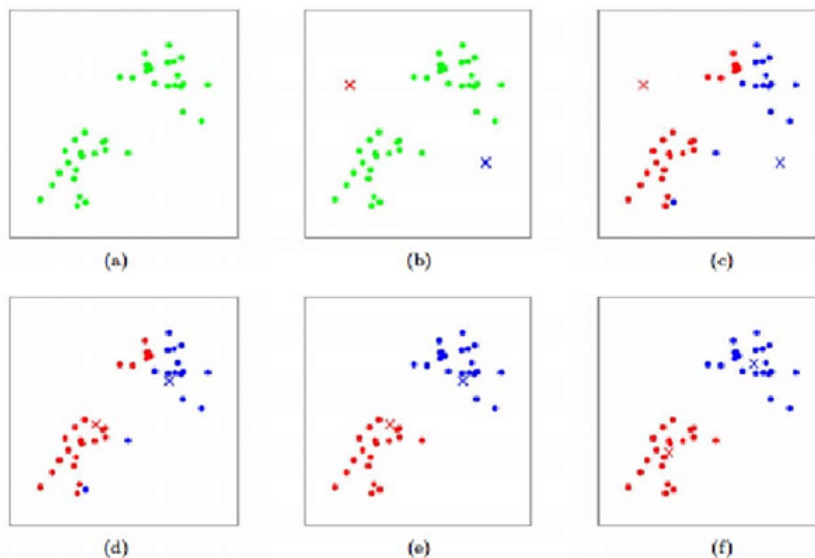
Olhando para as tabelas 3 e 4, se compararmos os valores de mAP e de FPS conseguimos concluir que o modelo YOLO é o mais adequado entre os três.

### 3 Tecnologias de detecção por agrupamento

Todas as técnicas mencionadas na secção anterior, apesar de eficazes na detecção de singulares, acabam por não ser bem-sucedidas quando escaladas para situações que envolvam muitos indivíduos, por exemplo para fazer detecções no coração de cidades muito populosas, como Lisboa, Pequim ou Nova York. Por exemplo, a previsão das trajetórias de um grupo de indivíduos com base nas trajetórias de cada um deles individualmente, é um problema complexo, uma vez que, as tecnologias tradicionais precisam de ter um conjunto muito grande de

dados para obterem uma previsão para a qual podemos olhar com mínima confiança e, mesmo assim, não podemos basear-nos nisso como algo absoluto. Esta limitação põe em causa estas técnicas, por uma série de razões como por exemplo a falta de poder computacional para detetar tantos indivíduos em tão pouco tempo. Numa tentativa de tentar resolver este problema chegamos à conclusão de que deveríamos usar técnicas de identificação por grupos, o que nos levou aos algoritmos de clustering. Clustering é uma técnica de aprendizagem de máquina não supervisionada que tem como objetivo agrupar dados semelhantes em conjuntos chamados clusters. Esta técnica é bastante utilizada nomeadamente em áreas como marketing, biologia, ciência da computação, entre outras.

Figura 5: Passos básicos do K-means onde  $k=2$ . (a) Dados iniciais. (b) Inicialização aleatória de centroides para agrupamento. (c-f) As duas primeiras iterações. (Imagem retirada de [11])




Os algoritmos de clustering são usados para realizar essa tarefa de agrupamento e são responsáveis por identificar padrões nos dados e separá-los em grupos de acordo com as similaridades que apresentam. Esses algoritmos podem ser baseados em diferentes métodos, como por exemplo distância, trajetórias, densidade ou hierarquia. [3]. Dentro dos algoritmos de clustering baseados em trajetórias, podemos identificar diferentes subcategorias. Alguns exemplos de algoritmos são os baseados em espaço, os baseados em partição e grupo, os de clustering dependentes do tempo, os de clustering de objeto em movimento baseado em rede rodoviária, os de clustering de trajetória semântica e os de clustering de trajetória incerta [3].

Os algoritmos baseados em espaço, tentam agrupar indivíduos consoante a similaridade espacial deles, como por exemplo qual a distância euclidiana de cada



Figura 6: a) Dados originais; (b) Resultados finais do RL-FCM; (c) Resultados finais do FCM com  $c = 6$  : (Imagem retirada de [10])




ponto. Um exemplo disto é o DBSCAN (Density-based spatial clustering of applications with noise ). Este algoritmo começa por dividir os dados que recebe em três tipos de pontos, os pontos centrais, ou seja os pontos que têm a um raio  $R$  definido à sua volta, sendo que requer um número mínimo de ponto predefinido, os pontos de periferia são os pontos que não são centrais, mas estão dentro do raio definido a algum ponto central. Por último temos os outliers, que são aqueles que não estão dentro do raio definido por algum ponto central, nem são pontos centrais. A segunda parte deste algoritmo consiste em escolher um ponto central qualquer e adquirir todos os pontos a  $R$  distância dele, este processo é repetido até não existirem mais pontos centrais, desta forma no final apenas obtemos um número de clusters e os outliers [3].(fig9)

Os algoritmos baseados em tempo agrupam os indivíduos consoante a sua ordem ou a sua sequência temporal. Com esta organização obtemos clusters dinâmicos, pois os pontos de cada cluster podem ser alterados ao longo do tempo, refletindo a evolução do processo que gerou os dados. Um exemplo de um algoritmo deste tipo é o T-OPTICS. Este algoritmo é uma variante do OPTICS, mas tem em consideração a dimensão temporal dos dados para identificar os clusters. Inicialmente, é criado um grafo de conectividade que une os pontos, permitindo desta forma identificar quais as áreas mais densas de pontos. A partir destas é construída uma hierarquia de clusters, onde as zonas mais densas são colocadas no centro e as zonas menos densas são colocadas na periferia [3].(fig7)

Os algoritmos de clustering baseados em partição e grupo dividem o conjunto de dados num número pré-definido de clusters. Um exemplo de um algoritmo destes é o K-means clustering. Este inicia-se com a escolha aleatória dos centros dos  $K$  clusters. Depois, através da distância euclidiana entre os outros pontos e os centros dos clusters vamos formar os  $k$  clusters. Obviamente que este processo vai ter de ser repetido um  $N$  número de vezes para encontrar a melhor distribuição dos  $K$  clusters, ou seja quando a diferença dos pontos entre cada um dos  $K$  clusters é menor. Para determinar o melhor  $K$  devemos iterativamente aumentá-lo, diminuindo a variação interna de cada cluster, até encontrar o  $K$  onde ocorre a diminuição mais abrupta de variação.(fig5)

Figura 7: Ilustração de um algoritmo T-OPTICS : (Imagem retirada de [13])



Os algoritmos de clustering de objeto em movimento baseado em rede rodoviária operam usando os dados de trajetória de veículos que se deslocam numa rede rodoviária. Eles procuram identificar grupos de veículos que apresentam comportamentos semelhantes na estrada, como por exemplo, em termos de trajetória, velocidade, direção e tempo de viagem [3].

Os algoritmos de clustering de trajetória semântica consideram as informações semânticas para agrupar trajetórias. Os algoritmos de clustering de trajetória incerta são usados para agrupar trajetórias de objetos que não seguem um padrão ou uma direção clara. Por outras palavras, eles lidam com trajetórias imprevisíveis, que podem envolver variações significativas na velocidade, direção e aceleração do objeto. Um exemplo deste tipo de algoritmo é o Fuzzy C-Means (FCM), que permite que um ponto esteja em mais do que um cluster [3].(fig6)

O STING começa por dividir os dados numa grade de células, criando um "grid". Cada célula tem uma estatística associada, que representa a distribuição dos pontos dentro da célula. Em seguida, ele usa a estatística das células para as agrupar em regiões maiores, e continua a fazer este processo até que todos os pontos de dados estejam agrupados [3].

O BIRCH tem duas etapas principais: a construção da árvore CF e a extração dos clusters a partir da árvore. Na primeira etapa, o algoritmo percorre os dados e insere resumos de cada ponto na árvore CF. A árvore é construída de tal forma que cada nó pode ter um número máximo de pontos e um número máximo de filhos. Quando um nó excede esses limites, ele é dividido em dois novos nós. Na segunda etapa, os clusters são extraídos da árvore usando um algoritmo de agrupamento hierárquico. O algoritmo usa uma distância entre os resumos de cada nó como critério para mesclar ou dividir os clusters [3].(fig8)

### 3.1 Vantagens na utilização de algoritmos de clustering

As tecnologias de clustering trazem várias vantagens e mais-valias para as aplicações de segurança rodoviária. Comparado à previsão de trajetórias individuais, é mais simples prever o movimento de um cluster de indivíduos. Ao agrupar

Figura 8: Ilustração do funcionamento do algoritmo BIRCH : (Imagem adaptada de [15]) Resnet = Residual neural network ou Rede Neural Residual em Português.





Figura 9: Um exemplo ilustratório do método DBSCAN (Imagem retirada de [12])



indivíduos com base em padrões de movimento semelhantes, é possível extrapolar o comportamento do grupo como um todo. Apesar de obviamente poderem aparecer outliers que se removem de um grupo, o movimento de um grupo junto é mais fácil de analisar. Outra vantagem, é que as técnicas de clustering são escaláveis, ou seja, são capazes de lidar com um grande número de indivíduos sem a necessidade de analisar trajetórias individuais, agrupando estes indivíduos em grupo tudo numa grande mancha a seguir a mesma trajetória. Isso torna essas tecnologias adequadas para aplicação em redes viárias com alta densidade populacional, algo extremamente complicado de fazer com tecnologias de machine-learning. Estas técnicas são também bastante versáteis, no sentido em que podemos aplicar as mesmas técnicas de clustering a carros, bicicletas e outras entidades da estrada, em situações de segurança, pois apenas importa se a trajetória de alguma destas entidades vai interceder a trajetória de algum indivíduo, colocando-o em risco, não sendo relevante reconhecermos estas entidades ou não. E uma das grandes mais valias que o clustering nos traz é que, através da análise da densidade das zonas que cada cluster abrange, é possível identificar zonas de maior concentração de indivíduos o que permite antecipar áreas de maior risco e adotar medidas de segurança adequadas.

### 3.2 Desvantagens na utilização de algoritmos de clustering

Apesar das suas vantagens, também existem alguns problemas com este tipo de técnicas. O mais claro é que a implementação de tecnologias de clustering requer sensores e sistemas computacionais adequados. Os custos associados à aquisição de sensores e processamento de grandes volumes de dados podem ser um desafio para sua adoção generalizada. Outro problema é que clustering não oferece personalização individualizada, o que pode dificultar a entrega de avisos específicos para cada indivíduo em tempo real. A falta de precisão individualizada pode impactar a eficácia das medidas de segurança sendo que em certos casos podemos ter indivíduos a receber avisos, sem correr perigo, dado que eles se encontram numa zona do cluster, potencialmente perigosa. Isto pode causar pânico em pessoas que estariam em segurança o que pode piorar uma situação.

## 4 Adaptação tecnológica no contexto das redes viárias

Uma possível abordagem tecnológica que nós consideramos promissora para melhorar a segurança rodoviária é a combinação de técnicas tradicionais com o uso de clustering. Esta integração de abordagens pode fornecer uma solução mais abrangente e adaptável para lidar com diferentes cenários e desafios encontrados nas redes viárias.

A ideia por trás desta é aproveitar as vantagens das técnicas tradicionais de machine-learning, que são capazes de analisar grandes volumes de dados e identificar padrões complexos, e aliá-los às capacidades do clustering de agrupar indivíduos com características semelhantes. Esta combinação permite uma compreensão mais profunda dos padrões de movimento e comportamento dos usuários vulneráveis das vias, como pedestres e ciclistas. As tecnologias de clustering em aplicações de segurança não devem eliminar as tecnologias tradicionais. Temos de usar ambos os avanços tecnológicos ao nosso favor, pois só assim vamos atingir sistemas de segurança completos. Por exemplo, se estamos perante uma iminência de colisão entre algum indivíduo e algum carro, o clustering por si não é o método recomendável para manter segurança das pessoas e nessas situações, um algoritmo de machine-learning conseguiria prever e identificar com muito mais sucesso, com base numa compreensão mais profunda dos padrões de movimento e comportamento dos usuários vulneráveis das vias, como pedestres e ciclistas.

### 4.1 Viabilidade

Ao combinar estas duas abordagens, é possível obter uma visão mais abrangente e detalhada das dinâmicas das redes viárias, levando em consideração, o comportamento individual dos usuários, como também, a análise de grupos e aglomerações. Desta forma, a tecnologia resultante é capaz de fornecer um

sistema de segurança mais completo e adaptável, abordando tanto situações específicas de indivíduos quanto riscos coletivos. Por exemplo, é possível aplicar algoritmos de clustering, como o DBSCAN, para identificar agrupamentos de URVs com base na densidade na distribuição nas vias. Esses agrupamentos podem ajudar a identificar áreas de maior concentração de usuários vulneráveis, possibilitando a adoção de medidas de segurança direcionadas. Nesta forma conseguiríamos prever em que áreas poderíamos alocar mais recursos específicos, colocando mais foco no clustering em zonas em que se junta muita gente e em zonas onde passa menos gente focaríamos mais tecnologias de detecção tradicionais. Mesmo assim convém realçar que acreditamos que o ideal seria sempre tentar colocar foco em ambos.

É importante ressaltar que a implementação bem-sucedida desta abordagem requer a colheita de dados precisos e confiáveis, sensores adequados e poder computacional suficiente para processar grandes quantidades de informação em tempo real. A implementação efetiva desta abordagem exige poder computacional suficiente para processar grandes volumes de dados em tempo real. Ambas as técnicas, podem ser muito computacionalmente intensivas, especialmente quando aplicadas a redes viárias complexas e em tempo real. Por isso, para uma combinação das duas convém sempre considerar algumas técnicas de otimização que nos vão ajudar a que o processo fique mais eficiente de um ponto de vista da complexidade. Para combinar as duas abordagens, também é necessário considerar integrarmos sistemas de machine-learning e clustering numa estrutura coesa. Isto envolve a seleção e implementação adequada de algoritmos, o desenvolvimento de modelos preditivos e a criação de uma infraestrutura que permita a comunicação e a troca de informações. A integração eficiente dos sistemas numa estrutura conjunta pode ser fundamental para garantir um desempenho adequado e obtermos melhores resultados. Além disso, é necessário considerar os desafios relacionados à privacidade e à segurança dos dados, garantindo que as informações coletadas sejam utilizadas de forma ética e protegida. Por exemplo, em [9], o autor fala que no ramo da pecuária é muito complicado em certas áreas rurais fazer tracking dos animais sem o uso de GPS nas coleiras. Como é óbvio, esta solução, se já é considerada dúbia em animais quanto mais em pessoas. Por isso, é sempre necessário ter em atenção a privacidade de uma pessoa e conseguir mesmo assim garantir a sua segurança.

## 4.2 Vantagens

Em primeiro lugar, todas as vantagens que realçamos sobre o uso de clusters nas vias rodoviárias vão se aplicar também nesta combinação. E seria também possível eliminar vários problemas que estes nos trazem. Para começar, as situações de avisos incorretos iriam diminuir, uma vez de que as tecnologias de machine-learning seriam capazes de analisar, indivíduos que se encontrem dentro do cluster, mas que não estejam perante nenhum risco considerável, diminuindo assim situações de pânico desnecessárias. Outra vantagem, que está relacionada com este exemplo, é uma melhor compreensão do contexto em que nos encontra-

mos. Com a utilização de técnicas de machine-learning vamos conseguir obter dados mais profundos sobre as características e interações específicas em diferentes regiões ou segmentos das redes viárias. Com esta comunhão de técnicas tornamos as aplicações muito mais adaptáveis a várias situações.

### 4.3 Desvantagens

A primeira grande desvantagem é algo a que já aludimos na parte da viabilidade, é necessário um poder computacional bastante grande para conseguir processar o grande volume de dados necessário e isso é algo que não é nada fácil de obter, principalmente grandes quantidades a preços acessíveis. A construção das estruturas em si é algo bastante dispendioso, já uma técnica há volta de muitos clusters, é algo bastante caro e que necessita de grande alocação de recursos, algo que os utilize aliado a machine-learning ainda mais alto seria a quantidade de recursos necessários. Para além disto, tanto as técnicas tradicionais de machine-learning quanto o clustering dependem da qualidade dos dados de entrada. Se os dados estiverem incompletos, desatualizados ou imprecisos a qualidade a precisão e a eficácia das análises vai ser menor e garantir uma colheita e a manutenção adequada dos dados para obter resultados confiáveis e significativos será algo bastante complicado.

### 4.4 Exemplos de potenciais usos

Ao combinar tecnologias tradicionais, como por exemplo câmaras de vigilância e sensores de presença em cruzamentos com técnicas de clustering, é possível melhorarmos na identificação de potenciais situações de risco e também detetar padrões de movimento em situações de risco de colisão. Um algoritmo de clustering, pode agrupar os veículos próximos e analisar os seus padrões de movimento. Com base nesses agrupamentos, é possível prever trajetórias e identificar cruzamentos com alto risco de colisão, permitindo a tomada de medidas preventivas, como alertar os condutores e os pedestres. Usando o método que estamos a propor, também é possível ajudar prevenir atropelamentos de URVs. Um algoritmo de clustering pode tratar da identificação de grupos de pedestres em zonas que sejam consideradas de risco, como passeadeiras ou perto de escolas. Com base nesses agrupamentos, é possível monitorizar o comportamento dos veículos próximos e identificar situações de risco iminente de atropelamento. Isso permite tomar atitudes em prol da segurança como acionar alertas aos condutores, modificar o tempo dos semáforos ou até mesmo ativar dispositivos de segurança, como sinalização luminosa para os URVs. Também podemos utilizar esta comunhão para monitorizar o comportamento dos condutores na estrada, mas convém termos em consideração que esta monitorização dos tem de ser feita de forma responsável, pois será daquelas medidas que poderá trazer alguma oposição de algumas pessoas. Apesar disto podemos utilizar a nossa combinação para identificar grupos de veículos que compartilham padrões semelhantes, como velocidade excessiva, mudanças de faixa frequentes sem grande coerência ou que

possuam uma condução agressiva. Estes agrupamentos podem ser usados para identificar áreas onde a aplicação de medidas de segurança, como reforço na fiscalização ou instalação de sinalização adicional, é necessária.

## 5 Conclusão

Como falamos na introdução do nosso artigo, a segurança rodoviária é uma preocupação contínua e, apesar dos avanços tecnológicos, ainda existem desafios a serem superados, especialmente no que diz respeito à proteção dos URV, como pedestres e ciclistas. Neste contexto, a combinação de técnicas tradicionais de machine-learning com o uso de clustering apresenta-se como uma abordagem promissora para melhorar a segurança nas redes viárias.

A utilização de técnicas de machine-learning permite uma análise profunda dos padrões de movimento e comportamento dos URVs, fornecendo uma compreensão mais abrangente e detalhada das dinâmicas das redes viárias. Por sua vez, o clustering oferece a capacidade de identificar agrupamentos de URVs com base na densidade de distribuição nas vias, o que permite uma abordagem direcionada na aplicação de medidas de segurança.

Esta combinação que propomos, é uma abordagem promissora para aprimorar a segurança rodoviária, especialmente no que diz respeito aos URV. No entanto, é necessário enfrentar desafios técnicos e garantir a qualidade dos dados e a privacidade das informações. Com a implementação adequada e o desenvolvimento contínuo dessas técnicas, podemos levar a segurança rodoviária a um nível mais avançado e desta forma proteger todos os usuários das vias de forma mais eficiente e eficaz.

## Referências

- [1] Iftikhar, S.; Zhang, Z.; Asim, M.; Muthanna, A.; Koucheryavy, A.; Abd El-Latif, A.A. Deep Learning-Based Pedestrian Detection in Autonomous Vehicles: Substantial Issues and Challenges. *Electronics* 2022, 11, 3551.
- [2] Valle, D., Cvetojevic, S., Robertson, E. et al. Individual Movement Strategies Revealed through Novel Clustering of Emergent Movement Patterns. *Sci Rep* 7, 44052 (2017).
- [3] Yuan, G., Sun, P., Zhao, J. et al. A review of moving object trajectory clustering algorithms. *Artif Intell Rev* 47, 123–144 (2017).
- [4] M. Bird, K. J. Koltun, M. Lovalekar, B. J. Martin, A. Fain, A. Bannister, A. V. Cruz, T. L. A. Doyle and B. C. Nindl (2022) Unsupervised Clustering Techniques Identify Movement Strategies in the Countermovement Jump Associated With Musculoskeletal Injury Risk During US Marine Corps Officer Candidates School

- [5] S. Bergen, M. M. Huso, A. E. Duerr, M. A. Braham, T. E. Katzner, S. Schmuecker, T. A. Miller (2022) Classifying behavior from short-interval biologging data: An example with GPS tracking of birds
- [6] M. Liebner, F. Klanner and C. Stiller, "Active safety for vulnerable road users based on smartphone position data," 2013 IEEE Intelligent Vehicles Symposium (IV), Gold Coast, QLD, Australia, 2013, pp. 256-261.
- [7] S. Khakpour, R. W. Pazzi, K. El-Khatib Using clustering for target tracking in vehicular ad hoc networks data, (2017) Vehicular Communications, Volume 9, Pages 83-96, ISSN 2214-2096,
- [8] J. Zhaoa, H. Xub, H. Liua, J. Wub, Y. Zhengb, Dayong Wu (2019) Detection and tracking of pedestrians and vehicles using roadside LiDAR sensors
- [9] X. Li, L. Xing Use of Unmanned Aerial Vehicles for Livestock Monitoring based on Streaming K-Means Clustering IFAC-PapersOnLine, Volume 52, Issue 30, 2019, Pages 324-329, ISSN 2405-8963.
- [10] M. Yang, Y. Nataliani Robust-learning fuzzy c-means clustering algorithm with unknown number of clusters Pattern Recognition Volume 71, November 2017, Pages 45-59
- [11] S. Yang, D. Towey and Z. Q. Zhou, "Metamorphic Exploration of an Unsupervised Clustering Program," 2019 IEEE/ACM 4th International Workshop on Metamorphic Testing (MET), Montreal, QC, Canada, 2019, pp. 48-54, doi: 10.1109/MET.2019.00015.
- [12] Khater IM, Nabi IR, Hamarneh G. A Review of Super-Resolution Single-Molecule Localization Microscopy Cluster Analysis and Quantification Methods. Patterns (N Y). 2020 Jun 12;1(3):100038. doi: 10.1016/j.patter.2020.100038. PMID: 33205106; PMCID: PMC7660399.
- [13] Israa S. Kamil, Safaa O. Al-Mamory, Enhancement of OPTICS' time complexity by using fuzzy clusters, Materials Today: Proceedings, Volume 80, Part 3, 2023, Pages 2625-2630, ISSN 2214-7853.
- [14] Nathan H. Danneman, Richard Heimann, Pradeepta Mishra (2017) R: Mining spatial, text, web, and social media data.
- [15] X. Li, W. Zhang, X. Sun, X. Gao Without detection: Two-step clustering features with local-global attention for image captioning IET Computer Vision Volume16, Issue 3, April 2022, Pages 280-294.
- [16] J. -a. Kim, J. -Y. Sung and S. -h. Park, "Comparison of Faster-RCNN, YOLO, and SSD for Real-Time Vehicle Type Recognition," 2020 IEEE International Conference on Consumer Electronics - Asia (ICCE-Asia), Seoul, Korea (South), 2020, pp. 1-4, doi: 10.1109/ICCE-Asia49877.2020.9277040.



- [17] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi You Only Look Once: Unified, Real-Time Object Detection
- [18] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu1, Alexander C. BergSSD: Single Shot MultiBox Detector
- [19] R. Girshick, J. Donahue, T. Darrell and J. Malik, "Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation," 2014 IEEE Conference on Computer Vision and Pattern Recognition, Columbus, OH, USA, 2014, pp. 580-587, doi: 10.1109/CVPR.2014.81.
- [20] Ross Girshick : Fast R-CNN
- [21] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun: Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks
- [22] Página da Wikipédia sobre câmara stereo : <https://en.wikipedia.org/wiki/Stereocamera>
- [23] Página da Wikipédia sobre LIDAR : <https://pt.wikipedia.org/wiki/Lidar>
- [24] Página da Wikipédia sobre Radar : <https://pt.wikipedia.org/wiki/Radar>
- [25] Página da Wikipédia sobre Infra Red : <https://en.wikipedia.org/wiki/Infrared>
- [26] Página da Wikipédia sobre Radio Frequência : <https://pt.wikipedia.org/wiki/Radiofrequência>
- [27] Página da Wikipédia sobre Ultra Sound : <https://en.wikipedia.org/wiki/Ultrasonictransducer>